

Laboratorio N° 1: Diseño de un MLP y Comparación con Modelos de Machine Learning para la Predicción del Rendimiento del Arroz en la India



UTEM

**UNIVERSIDAD
TECNOLÓGICA
METROPOLITANA**

Integrantes:

Patricio Abarca, Leonardo Solis, Rodrigo Tapia

**Facultad de Ingeniería
Departamento de Informática y Computación
EFE: Inteligencia Artificial
Profesor: Dr. Oscar Magna Veloso**

Septiembre de 2025



Índice

1. Contexto	3
1.1. Introducción	3
1.1.1. Contexto Global y la Necesidad de una Agricultura Inteligente	3
1.1.2. El Cultivo de Arroz en la India: Un Foco Estratégico	3
1.1.3. Inteligencia Artificial como Alternativa Accesible y Escalable	3
1.2. Justificación y Enfoque del Proyecto	3
2. Objetivos	3
2.1. Objetivo General	3
2.2. Objetivos Específicos	3
2.3. Hipótesis y Preguntas de Investigación	3
3. Metodología	4
3.1. Conjunto de Datos y Preprocesamiento	4
3.1.1. Focalización en el Cultivo de Arroz	4
3.1.2. Limpieza y Preparación de Datos	5
3.1.3. Enriquecimiento con Datos Geoespaciales	5
3.1.4. Enriquecimiento con Datos Temporales	5
3.1.5. Enriquecimiento con Datos Climáticos Externos	5
3.1.6. Enriquecimiento con Datos Edafológicos y Técnicas de Imputación	5
3.2. Preparación de los Datos para el Modelado	6
3.2.1. Selección y Transformación de Variables	6
3.2.2. Escalado de Características	6
3.2.3. División del Conjunto de Datos	6
3.2.4. Selección y Evaluación de Modelos	6
3.2.5. Diseño y Optimización del Perceptrón Multicapa (MLP)	7
3.2.6. Métricas de Evaluación Final	7
4. Resultados	7
4.1. Resultados del Análisis Exploratorio	7
4.1.1. Distribución de Variables Categóricas del Arroz	7
4.1.2. Distribución de Variables Numéricas	7
4.2. Resultados del Modelado	8
4.2.1. Evaluación Preliminar mediante Validación Cruzada	8
4.2.2. Rendimiento Final sobre el Conjunto de Prueba	9
4.2.3. Análisis Visual de las Predicciones por Modelo	9
5. Discusión de Resultados	11
5.1. Respuestas Directas a las Preguntas de Investigación	11
6. Conclusiones	12
A. Apéndice: Código Python Relevante	12
A.1. Función para Inferir Fechas de Cultivo	12
A.2. Función para Obtener Datos Climáticos de la NASA	13

Índice de figuras

1. Frecuencia de registros por tipo de cultivo en el dataset original.	4
2. Frecuencia de registros por Estado.	7
3. Frecuencia de registros por Temporada.	7
4. Distribución de Yield.	8
5. Distribución de Pesticide.	8
6. Distribución de Fertilizer.	8
7. Distribución de Annual Rainfall.	8
8. Distribución de Production.	8
9. Distribución de Area.	8
10. Distribución de registros por Crop Year.	8
11. RMSE promedio obtenido por cada modelo mediante validación cruzada en el conjunto de entrenamiento.	9
12. Comparación gráfica del rendimiento final de los modelos según RMSE, MAE y R^2	9
13. LightGBM ($R^2=0.552$)	10



14.	CatBoost ($R^2=0.521$)	10
15.	XGBoost ($R^2=0.477$)	10
16.	Random Forest ($R^2=0.464$)	10
17.	Ridge ($R^2=0.433$)	10
18.	Linear Regression ($R^2=0.433$)	10
19.	KNN ($R^2=0.363$)	10
20.	Decision Tree ($R^2=0.344$)	10
21.	SVR ($R^2=0.254$)	10
22.	MLP ($R^2=0.228$)	10
23.	Lasso ($R^2=-0.015$)	10
24.	Grilla comparativa de gráficos de dispersión (Predicciones vs. Valores Reales) para los 11 modelos. . .	10

Índice de cuadros

1.	Resultados comparativos de los modelos en el conjunto de prueba.	9
----	--	---

Listings

1.	Función para asignar fechas de siembra y cosecha según la temporada.	12
2.	Función para consultar la API POWER de la NASA y obtener datos climáticos.	13



1. Contexto

1.1. Introducción

1.1.1. Contexto Global y la Necesidad de una Agricultura Inteligente

La agricultura mundial enfrenta el desafío de aumentar en un 70 % su producción al 2050 para alimentar a más de 9,000 millones de personas (FAO). Factores como el cambio climático, la degradación de recursos y la sostenibilidad exigen nuevas estrategias. La agricultura de precisión, apoyada en datos y análisis predictivo, surge como herramienta esencial para optimizar insumos, reducir impactos y mejorar la rentabilidad.

1.1.2. El Cultivo de Arroz en la India: Un Foco Estratégico

La India depende fuertemente de la agricultura, y el arroz es su principal cultivo básico. Su producción enfrenta retos como la dependencia de monzones, la predominancia de pequeñas explotaciones y la diversidad agroclimática, lo que demanda soluciones accesibles y adaptables. Optimizar su rendimiento es prioritario para la seguridad alimentaria nacional.

1.1.3. Inteligencia Artificial como Alternativa Accesible y Escalable

Aunque existen modelos agronómicos complejos, su costo y dificultad limitan su uso. La Inteligencia Artificial, en particular el Perceptrón Multicapa (MLP), ofrece una alternativa eficiente y práctica para modelar variables climáticas, de suelo y manejo, facilitando aplicaciones reales sin requerir grandes recursos.

1.2. Justificación y Enfoque del Proyecto

Este proyecto propone una solución basada en IA para predecir el rendimiento del arroz en la India mediante un MLP aplicado a datos específicos. Se busca generar predicciones confiables y, al mismo tiempo, promover el uso del aprendizaje automático en un ámbito de alto impacto social y económico.

2. Objetivos

2.1. Objetivo General

Diseñar e implementar un modelo de red neuronal artificial de tipo Perceptrón Multicapa (MLP) capaz de predecir con precisión el rendimiento del cultivo de **arroz** (en toneladas por hectárea) dentro del diverso entorno agrícola de la India. El modelo se basará en datos históricos que incluyen variables climáticas, regionales y de manejo agronómico.

2.2. Objetivos Específicos

- Preparar y Filtrar los Datos:** Adquirir el conjunto de datos agrícolas, realizar un preprocesamiento exhaustivo y focalizar el análisis exclusivamente en el cultivo de arroz, gestionando valores atípicos y categóricos para asegurar la calidad de los datos de entrada.
- Realizar un Análisis Exploratorio:** Ejecutar un Análisis Exploratorio de Datos (EDA) sobre el subconjunto de datos de arroz para identificar relaciones clave entre las variables y visualizar patrones de producción entre diferentes estados y temporadas.
- Diseñar y Entrenar el Modelo MLP:** Construir y optimizar un modelo de Perceptrón Multicapa, ajustando sus hiperparámetros (número de capas, neuronas, tasa de aprendizaje) para maximizar su capacidad predictiva sobre los datos de rendimiento del arroz.
- Evaluar el Desempeño del Modelo:** Medir la eficacia del modelo final utilizando métricas de regresión estándar como el Coeficiente de Determinación (R^2) y el Error Cuadrático Medio Raíz (RMSE).
- Analizar la Importancia de las Variables:** Determinar qué factores tienen el mayor impacto en la predicción del rendimiento del arroz, con el fin de aportar interpretabilidad a los resultados del modelo.

2.3. Hipótesis y Preguntas de Investigación

El proyecto se sustenta en las siguientes tres hipótesis que permiten evaluar tanto el desempeño técnico del modelo MLP como su aplicabilidad práctica en el contexto agronómico:

- Hipótesis Principal ($H1$):** Un modelo MLP entrenado con datos integrados de suelo, clima y manejo agronómico puede predecir el rendimiento de cultivos con un error absoluto medio (MAE) inferior al 10 % del rendimiento promedio observado en el conjunto de datos, superando significativamente el desempeño de modelos lineales simples.



2. **Hipótesis Secundaria (H_2):** Las variables climáticas (especialmente precipitación acumulada y temperatura media) y las relacionadas con el contenido de nitrógeno en el suelo tienen un peso significativamente mayor en la predicción del rendimiento que otras variables.
3. **Hipótesis de Interpretabilidad (H_3):** A pesar de su naturaleza de caja negra, un modelo MLP bien entrenado y analizado mediante técnicas como la permutación de características puede ofrecer insights interpretables y alineados con conocimientos agronómicos establecidos.

Asimismo, se busca dar respuesta a las siguientes interrogantes:

1. ¿Qué combinación de variables del suelo, clima y manejo agronómico tiene mayor impacto en la predicción del rendimiento?
2. ¿Cuál es la arquitectura óptima del MLP (número de capas, neuronas, función de activación) para este problema de regresión?
3. ¿Cómo afecta la calidad y completitud de los datos (valores faltantes, ruido, desbalance) al desempeño del modelo?
4. ¿Es posible obtener una predicción precisa del rendimiento sin utilizar datos de series temporales largas o imágenes satelitales?
5. ¿Qué nivel de interpretabilidad puede alcanzarse en un modelo MLP aplicado a un dominio agronómico crítico?

3. Metodología

3.1. Conjunto de Datos y Preprocesamiento

El estudio se basó en un conjunto de datos público sobre el rendimiento de cultivos en la India obtenido en Kaggle [1], que abarca el período de 1997 a 2020. El dataset original contenía **19,689 registros** que incluían 55 cultivos diferentes.

Las variables principales del conjunto de datos son:

- **Crop:** Nombre del cultivo.
- **Crop_Year:** Año de cosecha.
- **Season:** Estación agrícola (*Kharif*, *Rabi*, etc.).
- **State:** Estado de la India.
- **Area:** Superficie cultivada (hectáreas).
- **Production:** Producción total (toneladas).
- **Annual_Rainfall:** Precipitación anual (mm).
- **Fertilizer:** Fertilizantes aplicados (kg).
- **Pesticide:** Pesticidas utilizados (kg).
- **Yield:** Rendimiento del cultivo (producción por área).

3.1.1. Focalización en el Cultivo de Arroz



Figura 1: Frecuencia de registros por tipo de cultivo en el dataset original.

Durante el Análisis Exploratorio de Datos (EDA) inicial, se observó que el **arroz (Rice)** era el cultivo con mayor número de registros (11,970), además de ser el alimento de mayor importancia estratégica para la India. Con el objetivo de desarrollar un modelo más preciso y especializado, se tomó la decisión de filtrar el conjunto de datos para trabajar exclusivamente con las entradas correspondientes a este cultivo.



3.1.2. Limpieza y Preparación de Datos

Una vez aislado el subconjunto de datos de arroz, se procedió a una fase de limpieza enfocada en la variable **Season** para garantizar la coherencia de los datos temporales:

1. **Análisis de la variable Season:** Se identificó la presencia de la categoría '**Whole Year**'. Se determinó que esta etiqueta carecía de la especificidad necesaria para el análisis.
2. **Eliminación de la categoría 'Whole Year':** Se eliminaron estos registros para no introducir ambigüedad en el modelo.
3. **Estandarización de etiquetas:** Se aplicó un proceso para eliminar espacios en blanco al inicio y al final de los valores de la columna **Season**.

Tras este proceso de filtrado y limpieza, el conjunto de datos final para el análisis y entrenamiento del modelo quedó conformado por **1,160 registros**.

3.1.3. Enriquecimiento con Datos Geoespaciales

Para añadir una dimensión espacial al análisis, se enriqueció el dataset incorporando las coordenadas geográficas (**Latitud** y **Longitud**) de cada estado. Este proceso se realizó mediante un cruce con un archivo externo [7] y se completó de forma manual para los estados sin correspondencia usando los datos de otra web [4], asegurando que el 100 % de los 1,160 registros tuvieran datos de geolocalización precisos.

3.1.4. Enriquecimiento con Datos Temporales

Con el fin de transformar la variable categórica **Season** en información temporal cuantitativa, se crearon dos nuevas columnas: **Planting_Date** (Fecha de Siembra) y **Harvest_Date** (Fecha de Cosecha). Se desarrolló una función que infiere un rango de fechas aproximado para cada temporada, permitiendo definir un intervalo de tiempo específico para cada registro.

3.1.5. Enriquecimiento con Datos Climáticos Externos

- **Precip_Accumulated:** Precipitación total acumulada durante el periodo de cultivo (derivada de 'PRECTOT-CORR').
- **Temp_Mean:** Temperatura media del periodo (derivada de 'T2M').
- **Sun_Hours:** Una estimación de las horas de sol, calculada a partir de la radiación solar de onda corta (derivada de 'ALLSKY_SFC_SW_DWN').

Se implementó un sistema de caché en un archivo JSON para almacenar los resultados de la API, minimizando llamadas repetidas en futuras ejecuciones. El dataframe enriquecido se guardó en `df_rice_after_api.csv` para su uso posterior.

3.1.6. Enriquecimiento con Datos Edafológicos y Técnicas de Imputación

Reconociendo la importancia crítica del suelo, se realizó un enriquecimiento de datos en varias etapas para incorporar variables edafológicas.

Obtención de Datos Base: Se utilizó la **API GraphQL de WoSIS (World Soil Information Service)** [2] para obtener perfiles de suelo cercanos a las coordenadas de cada cultivo. Las variables extraídas incluyeron:

- **Soil_pH:** Nivel de pH del suelo.
- **Soil_Humidity:** Humedad del suelo (de 'wg0006Values').
- **Soil_Nitrogen:** Nitrógeno total (de 'nitkjdValues').
- **Soil_Phosphorus:** Fósforo (de 'phetolValues').
- **Soil_Organic_Carbon:** Carbono orgánico (de 'orgmValues').

Debido a la dispersión de los puntos de muestreo de WoSIS, la consulta inicial resultó en una cantidad significativa de valores nulos.



Imputación de Datos Faltantes: Para completar el dataset, se aplicó una estrategia de imputación secuencial:

1. **Aproximación por Perfil Cercano:** Para los registros con datos faltantes, se buscó en el conjunto de todos los perfiles de suelo obtenidos de la API y se asignaron los valores del perfil geográficamente más cercano.
2. **Relleno Basado en Literatura Científica:** Las variables que aún contenían valores nulos, como **Soil_Potassium**, o que requerían mayor robustez, fueron completadas generando datos sintéticos a partir de distribuciones estadísticas descritas en la literatura:
 - Para **Carbono Orgánico, Fósforo y Potasio**, se generaron valores a partir de una distribución normal truncada, utilizando las medias, desviaciones estándar y rangos reportados por Sharma et al. [6] para suelos de arroz en la llanura indogangética.
 - Para la **Humedad del Suelo**, los valores faltantes se rellenaron con una distribución uniforme, utilizando el rango de 44.16 % a 50.66 % observado por Jayanthi et al. [3].

Este proceso de múltiples pasos aseguró un conjunto de datos completo y robusto, combinando datos de API con conocimiento experto extraído de investigaciones relevantes, dejando el dataframe listo para la fase de modelado.

3.2. Preparación de los Datos para el Modelado

Una vez consolidado el conjunto de datos enriquecido, se procedió a su preparación final para el entrenamiento de los modelos de aprendizaje automático. Este proceso constó de varias etapas clave:

3.2.1. Selección y Transformación de Variables

Se definieron las variables predictoras (X) y la variable objetivo (y). La variable a predecir fue **Yield** (rendimiento del cultivo). Para las variables, se realizó el siguiente tratamiento:

1. **Transformación de Fechas:** Se extrajo el mes de las columnas **Planting_Date** y **Harvest_Date** para crear dos nuevas características numéricas: **Planting_Month** y **Harvest_Month**.
2. **Ajuste de la Variable Objetivo:** La variable **Yield** fue convertida a toneladas por hectárea, una unidad estándar que facilita la interpretación del rendimiento del modelo.
3. **Selección de Variables Finales:** Se eliminaron las columnas que ya no eran pertinentes para el entrenamiento, como las fechas originales, las coordenadas y el nombre del cultivo (**Crop**).
4. **Codificación de Variables Categóricas:** Las columnas **State** y **Season** fueron transformadas utilizando **One-Hot Encoding**, creando columnas binarias para cada categoría y evitando así que el modelo asuma una relación ordinal inexistente.

El resultado de este proceso fue un dataframe puramente numérico, guardado como **df_rice_prepared.csv**, , quedó conformado por 50 columnas y listo para el entrenamiento.

3.2.2. Escalado de Características

Las variables numéricas del conjunto de datos, como el área, la precipitación o la cantidad de fertilizante, se encuentran en escalas muy diferentes. Para que los modelos, especialmente los sensibles a la escala como el MLP, converjan de manera eficiente y no sesguen su aprendizaje hacia las variables con magnitudes más grandes, se aplicó un **escalado de características**. Se utilizó el **StandardScaler**, que transforma cada característica para que tenga una media de 0 y una desviación estándar de 1.

3.2.3. División del Conjunto de Datos

Finalmente, el conjunto de datos se dividió en dos subconjuntos:

- **Conjunto de Entrenamiento (80 %):** Utilizado para entrenar los modelos, permitiéndoles aprender los patrones subyacentes en los datos.
- **Conjunto de Prueba (20 %):** Utilizado para evaluar el rendimiento de los modelos en datos no vistos, proporcionando una medida objetiva de su capacidad de generalización.

3.2.4. Selección y Evaluación de Modelos

Se llevó a cabo un proceso de evaluación en dos etapas. Primero, se realizó una validación cruzada (*cross-validation*) con 5 pliegues sobre el conjunto de entrenamiento para obtener una estimación robusta del rendimiento de 10 modelos base. Los modelos evaluados fueron:

- **Modelos Clásicos:** Linear Regression, Ridge, Lasso, Decision Tree, Random Forest, Support Vector Regressor (SVR) y K-Nearest Neighbors (KNN).
- **Modelos de Ensamblado (Boosting):** XGBoost, LightGBM y CatBoost.



3.2.5. Diseño y Optimización del Perceptrón Multicapa (MLP)

Como uno de los modelos centrales del estudio, se diseñó un Perceptrón Multicapa (MLP) cuya arquitectura fue definida con base en la complejidad del problema y las mejores prácticas para evitar el sobreajuste. Las decisiones clave fueron:

- **Arquitectura de Capas y Neuronas:** Para capturar las relaciones no lineales de los datos sin crear un modelo excesivamente complejo para el tamaño del dataset, se implementó una arquitectura de **tres capas ocultas**. El número de neuronas por capa se estableció de forma decreciente (de $n_{\text{features}} * 3$ a n_{features}), permitiendo que la red aprenda patrones complejos en las capas iniciales y los refine en las más profundas.
- **Funciones de Activación:** Se empleó la función **ReLU (Rectified Linear Unit)** en las capas ocultas. Esta elección se basa en su eficiencia computacional y su robustez contra el problema del desvanecimiento de gradientes. Para la capa de salida, se utilizó la activación lineal implícita, estándar para tareas de regresión.
- **Optimizador:** Se seleccionó el optimizador **Adam** por su amplio reconocimiento como una opción robusta y eficiente que generalmente funciona bien con una configuración predeterminada.
- **Regularización y Tasa de Aprendizaje:** Para controlar el sobreajuste, se incluyó un término de regularización **L2 (parámetro alpha)**. Tanto este parámetro como la tasa de aprendizaje inicial (`learning_rate_init`) fueron los hiperparámetros seleccionados para ser afinados.

Para encontrar la configuración óptima, se realizó una búsqueda en malla con validación cruzada (`GridSearchCV`). Este proceso identificó que los mejores valores eran `alpha=0.01` y `learning_rate_init=0.01`.

3.2.6. Métricas de Evaluación Final

Finalmente, todos los modelos (incluyendo el MLP ya optimizado) fueron entrenados con el conjunto completo de entrenamiento y evaluados una última vez sobre el **conjunto de prueba**. El rendimiento definitivo se midió con las métricas: Error Cuadrático Medio Raíz (RMSE), Error Absoluto Medio (MAE) y el Coeficiente de Determinación (R^2).

4. Resultados

4.1. Resultados del Análisis Exploratorio

4.1.1. Distribución de Variables Categóricas del Arroz

El análisis de las variables categóricas reveló patrones geográficos y estacionales muy marcados. Como se observa en la Figura 2, el estado de **Assam** es el que cuenta con la mayor cantidad de registros (más de 150), seguido por Karnataka y West Bengal. Esto indica que las operaciones agrícolas documentadas en el dataset se concentran mayoritariamente en estas regiones.

En cuanto a la estacionalidad (Figura 3), la temporada **Kharif** (el monzón de verano) domina de forma abrumadora, lo que confirma la fuerte dependencia del cultivo de arroz de este patrón climático en la India.




Figura 2: Frecuencia de registros por Estado.




Figura 3: Frecuencia de registros por Temporada.

4.1.2. Distribución de Variables Numéricas

Se generaron histogramas (Figuras 4 a 10) para analizar la distribución de las variables numéricas clave. Se identificó una fuerte **asimetría positiva (sesgo a la derecha)** en variables cruciales como **Area**, **Production**, **Fertilizer** y **Pesticide**. Esto sugiere que la mayoría de los cultivos se realizan en áreas pequeñas con un uso moderado de insumos, pero existen unos pocos casos atípicos de operaciones a gran escala que generan una cola larga en la distribución.



Esta asimetría es un hallazgo importante, ya que puede afectar negativamente el rendimiento de ciertos modelos de regresión, especialmente los lineales. En contraste, la variable **Annual_Rainfall** muestra una distribución más cercana a la normal.

Finalmente, el análisis de **Crop_Year** (Figura 10) indica que los datos están bien distribuidos a lo largo del período de estudio (1997-2020), lo que asegura una buena cobertura temporal para el entrenamiento del modelo.




Figura 4: Distribución de Yield.




Figura 5: Distribución de Pesticide.




Figura 6: Distribución de Fertilizer.




Figura 7: Distribución de Annual Rainfall.




Figura 8: Distribución de Production.




Figura 9: Distribución de Area.




Figura 10: Distribución de registros por Crop Year.

4.2. Resultados del Modelado

La fase de modelado se ejecutó en dos etapas secuenciales: una evaluación preliminar para identificar los algoritmos más prometedores y una evaluación final y detallada sobre el conjunto de prueba para determinar el modelo ganador y analizar su comportamiento.

4.2.1. Evaluación Preliminar mediante Validación Cruzada

Inicialmente, se realizó una validación cruzada de 5 pliegues sobre el conjunto de entrenamiento. La Figura 11 presenta el RMSE promedio obtenido por los modelos en esta fase. Este análisis temprano fue crucial, ya que perfiló a los algoritmos de Gradient Boosting (**CatBoost**, **XGBoost**, **LightGBM**) como los candidatos más fuertes, al exhibir los errores más bajos.




Figura 11: RMSE promedio obtenido por cada modelo mediante validación cruzada en el conjunto de entrenamiento.

4.2.2. Rendimiento Final sobre el Conjunto de Prueba

La evaluación definitiva se llevó a cabo sobre el conjunto de prueba, utilizando datos que los modelos no habían visto previamente. La Tabla 1 resume el desempeño de los 11 modelos, confirmando la superioridad de los ensambles.

Cuadro 1: Resultados comparativos de los modelos en el conjunto de prueba.

Modelo	RMSE	MAE	R ²
Lasso	0.089	0.063	-0.015
MLP	0.077	0.044	0.228
SVR	0.076	0.049	0.254
Decision Tree	0.071	0.035	0.344
KNN	0.070	0.034	0.363
Linear Regression	0.066	0.032	0.433
Ridge	0.066	0.032	0.433
Random Forest	0.065	0.027	0.464
XGBoost	0.064	0.028	0.477
CatBoost	0.061	0.025	0.521
LightGBM	0.059	0.027	0.552

El modelo **LightGBM** se consolidó como el ganador, con un R^2 de **0.552**, lo que indica que es capaz de explicar el 55.2% de la variabilidad en el rendimiento del cultivo. La Figura 12 ilustra esta comparativa, mostrando una clara brecha en rendimiento entre los modelos de boosting y el resto.




Figura 12: Comparación gráfica del rendimiento final de los modelos según RMSE, MAE y R^2 .

4.2.3. Análisis Visual de las Predicciones por Modelo

Para un análisis cualitativo, se generaron gráficos de dispersión (Predicciones vs. Valores Reales) para cada modelo. La Figura 24 los agrupa para una comparación visual directa, ordenados de mejor a peor rendimiento según R^2 .




Figura 13: LightGBM ($R^2=0.552$)




Figura 14: CatBoost ($R^2=0.521$)




Figura 15: XGBoost ($R^2=0.477$)




Figura 16: Random Forest ($R^2=0.464$)




Figura 17: Ridge ($R^2=0.433$)




Figura 18: Linear Regression ($R^2=0.433$)




Figura 19: KNN ($R^2=0.363$)




Figura 20: Decision Tree ($R^2=0.344$)




Figura 21: SVR ($R^2=0.254$)




Figura 22: MLP ($R^2=0.228$)




Figura 23: Lasso ($R^2=-0.015$)

Figura 24: Grilla comparativa de gráficos de dispersión (Predicciones vs. Valores Reales) para los 11 modelos.

De la grilla visual se extraen conclusiones clave: los modelos de **Gradient Boosting** (fila superior) y **Random Forest** muestran una clara correlación lineal, validando su superioridad. Conforme el R^2 disminuye, la nube de puntos se vuelve más dispersa y menos definida, hasta llegar al caso de **Lasso**, que no muestra ninguna capacidad para capturar la tendencia de los datos.



5. Discusión de Resultados

El análisis de resultados permitió evaluar de manera crítica las hipótesis planteadas en el presente estudio. En relación con la **hipótesis principal (H1)**, los experimentos demostraron que el modelo MLP alcanzó un MAE de 0.044, valor considerablemente inferior al umbral del 10 % del rendimiento promedio (0.23). Este resultado confirma la capacidad del modelo para aproximar adecuadamente las relaciones no lineales entre las variables. No obstante, la comparación con enfoques alternativos evidenció que la regresión Ridge obtuvo un MAE de 0.032, lo que indica que el MLP no superó significativamente a los modelos lineales regulares. En consecuencia, la hipótesis principal se valida solo de manera parcial.

Respecto a la **hipótesis secundaria (H2)**, los hallazgos refutaron lo inicialmente planteado. El análisis de importancia de características realizado sobre el modelo con mejor desempeño (LightGBM) mostró que las variables asociadas al **manejo agronómico directo** (fertilizante y pesticida), junto con el **área cultivada**, constituyeron los predictores más relevantes. En contraste, las variables climáticas y edáficas, si bien contribuyeron en cierta medida, ocuparon un rol secundario. Este resultado sugiere que, bajo las condiciones del conjunto de datos analizado, las decisiones de manejo ejercen una influencia más determinante sobre el rendimiento que los factores ambientales.

En cuanto a la **hipótesis de interpretabilidad (H3)**, los resultados obtenidos la confirmaron plenamente. El empleo de técnicas post-hoc de interpretabilidad en el modelo ganador permitió identificar y jerarquizar las variables más influyentes, proporcionando explicaciones consistentes con el conocimiento agronómico existente. Este hallazgo demuestra que incluso modelos complejos pueden ser auditados para generar información confiable y aplicable en la práctica agrícola.

De forma complementaria, las respuestas a los interrogantes de investigación refuerzan estas conclusiones. El impacto relativo de las variables indica la primacía del manejo de insumos y las dimensiones del cultivo sobre los factores climáticos; la búsqueda de la mejor arquitectura del MLP evidenció que este modelo no alcanzó un desempeño competitivo frente a los métodos de ensamble; la calidad y completitud de los datos se corroboraron como factores críticos para la viabilidad del modelado; y se verificó la posibilidad de obtener predicciones razonablemente precisas sin recurrir a datos satelitales o de series temporales, siempre que exista un adecuado enriquecimiento de variables. Finalmente, el nivel de interpretabilidad alcanzado resultó suficiente para derivar conclusiones alineadas con el dominio agronómico, reforzando la utilidad práctica de los modelos desarrollados.

En síntesis, si bien el MLP no constituyó la arquitectura más adecuada para este problema en particular, el estudio permitió demostrar la relevancia de la calidad de los datos y de la interpretabilidad como pilares fundamentales para el diseño de soluciones de agricultura inteligente en contextos reales.

5.1. Respuestas Directas a las Preguntas de Investigación

1. **¿Qué combinación de variables del suelo, clima y manejo agronómico tiene mayor impacto en la predicción del rendimiento?**

El análisis evidenció que las variables de manejo agronómico directo (fertilizante y pesticida), junto con el área cultivada, tienen el mayor peso en la predicción del rendimiento. Las variables climáticas y edáficas aportaron información adicional, pero en un rol secundario.

2. **¿Cuál es la arquitectura óptima del MLP (número de capas, neuronas, función de activación) para este problema de regresión?**

La mejor arquitectura obtenida incluyó 3 capas ocultas con número de neuronas decreciente, función de activación ReLU en las capas ocultas, salida lineal y el optimizador Adam, con hiperparámetros ajustados (`alpha=0.01`, `learning rate=0.01`). No obstante, su desempeño ($R^2=0.228$) fue limitado en comparación con los modelos de ensamble.

3. **¿Cómo afecta la calidad y completitud de los datos (valores faltantes, ruido, desbalance) al desempeño del modelo?**

La calidad y completitud de los datos resultaron factores críticos. El enriquecimiento mediante APIs externas (NASA POWER, WoSIS) y las técnicas de imputación fueron indispensables para obtener un dataset utilizable y lograr predicciones viables. Sin este proceso, el modelado no habría sido factible.

4. **¿Es posible obtener una predicción precisa del rendimiento sin utilizar datos de series temporales largas o imágenes satelitales?**

Sí. El estudio demostró que es posible alcanzar predicciones razonablemente precisas ($R^2=0.552$ con LightGBM) utilizando únicamente datos agregados por temporada y enriquecidos con variables climáticas y edáficas estáticas, sin necesidad de recurrir a series temporales extensas ni imágenes satelitales.

5. **¿Qué nivel de interpretabilidad puede alcanzarse en un modelo MLP aplicado a un dominio agronómico crítico?**

Se alcanzó un nivel interpretativo alto mediante técnicas post-hoc, que permitieron identificar y jerarquizar las variables más influyentes. Esto proporcionó explicaciones consistentes con el conocimiento agronómico, demostrando que incluso modelos complejos pueden entregar información práctica y confiable.



6. Conclusiones

Este estudio evaluó modelos de aprendizaje automático para predecir el rendimiento de arroz en India (1997–2020) a partir de datos climáticos, edáficos y de manejo agronómico, tras un riguroso preprocesamiento y enriquecimiento con NASA POWER y WoSIS. Se compararon once algoritmos de regresión mediante validación cruzada y un conjunto de prueba final ($n = 1.160$, 50 características).

Los resultados muestran que los modelos de *gradient boosting*, especialmente LightGBM ($R^2 = 0,552$), superan al MLP ($R^2 = 0,228$, MAE = 0.044), indicando que los ensambles basados en árboles logran un mejor balance entre sesgo y varianza para este dataset. El análisis de importancia de variables revela que las decisiones de manejo (fertilizante, pesticida, área) son los principales predictores, seguidos de variables climáticas y edáficas.

La calidad y completitud de los datos fueron críticas; imputaciones y generación sintética permitieron completar el dataset, pero introducen incertidumbre. Se detectaron sesgos geográficos y estacionales, limitando la generalización. Técnicas post-hoc aplicadas a LightGBM permitieron interpretabilidad útil, mientras que el MLP requiere métodos adicionales (SHAP, LIME) para explicar resultados.

El estudio demuestra que es posible obtener predicciones útiles sin series temporales largas ni imágenes satelitales, aunque su inclusión (NDVI, series de mayor resolución) podría mejorar la precisión. Limitaciones incluyen el tamaño y distribución del dataset, dependencia de imputaciones, exploración limitada de arquitecturas neuronales y falta de validación externa.

Se recomiendan acciones futuras: optimización de LightGBM, incorporación de datos espaciales y temporales adicionales, mejora en la recolección de datos edáficos, estrategias de validación robustas, exploración de enfoques híbridos y análisis causales de variables de manejo.

En síntesis, los ensambles basados en árboles constituyen la opción más efectiva para este problema, mientras que el MLP ofrece estimaciones aceptables pero inferiores. Los resultados resaltan la prioridad de mejorar la calidad de datos de manejo y suelo e integrar fuentes temporales y espaciales para avanzar hacia modelos más precisos y útiles en agricultura de precisión.

Referencias

- [1] Akshat Gupta et al. Agricultural crop yield in indian states dataset. <https://www.kaggle.com/datasets/akshatgupta7/crop-yield-in-indian-states-dataset>, 2023. Consultado: 29 de agosto de 2025.
- [2] ISRIC - World Soil Information. Wosis (world soil information service) graphql api. <https://graphql.isric.org/wosis/graphql>, 2025. Consultado: 23 de septiembre de 2025.
- [3] M Jayanthi, R Kalaiselvi, K Poongodi, and R Soumya. Critical analysis of soil for better rice and sugarcane farming in thanjavur region of india. *Advances in Agriculture & Botany- International Journal of the TIGR*, 10(4), 2018.
- [4] Maps of India. Maps of india. <https://www.mapsofindia.com/>, 2025. Consultado: 03 de septiembre de 2025.
- [5] NASA Langley Research Center (LaRC) POWER Project. Prediction of Worldwide Energy Resources (POWER) Data. <https://power.larc.nasa.gov/>, 2025. Datos consultados para el periodo 1997-2020. Accedido: 06 de septiembre de 2025.
- [6] B. Sharma, Sidhu Sidhu, D. Sarkar, and Surinder Kukal. Soil organic carbon, phosphorous, and potassium status in rice-wheat soils of different agro-climatic zones in indo-gangetic plains of india. *Communications in Soil Science and Plant Analysis - COMMUN SOIL SCI PLANT ANAL*, 43:1449–1467, 05 2012.
- [7] Simplemaps. India cities database. <https://simplemaps.com/data/in-cities>, 2025. Consultado: 03 de septiembre de 2025.

A. Apéndice: Código Python Relevante

A.1. Función para Inferir Fechas de Cultivo

```
1 def infer_dates(season, year):
2     """
3     Infers approximate planting and harvest dates based on season and year.
4     """
5     if season == 'Kharif':
6         return f'{year}-06-01', f'{year}-10-31'
7     elif season == 'Rabi':
8         return f'{year}-11-01', f'{year+1}-04-30'
9     elif season == 'Summer':
10        return f'{year}-03-01', f'{year}-06-30'
11    elif season == 'Autumn':
```



```
12     return f'{year}-09-01', f'{year}-12-31'
13 elif season == 'Winter':
14     return f'{year}-11-01', f'{year+1}-03-31'
15 else:
16     return None, None
```

Listing 1: Función para asignar fechas de siembra y cosecha según la temporada.

A.2. Función para Obtener Datos Climáticos de la NASA

```
1 import requests
2 import json
3
4 def get_nasa_power_data(lat, lng, start_date, end_date):
5     """
6     Fetch monthly climate data from NASA POWER API.
7     Parameters: PRECTOTCORR, T2M, ALLSKY_SFC_SW_DWN
8     """
9     base_url = "https://power.larc.nasa.gov/api/temporal/monthly/point"
10    params = {
11        "parameters": "PRECTOTCORR,T2M,ALLSKY_SFC_SW_DWN",
12        "community": "AG",
13        "longitude": lng,
14        "latitude": lat,
15        "start": start_date.replace('-', ''),
16        "end": end_date.replace('-', ''),
17        "format": "JSON"
18    }
19    response = requests.get(base_url, params=params)
20    if response.status_code == 200:
21        return response.json()
22    else:
23        return None
```

Listing 2: Función para consultar la API POWER de la NASA y obtener datos climáticos.