



RiceYield AI. Agricultura Inteligente para Pequeños Productores (Línea de Proyectos Asignatura IA)

Patricio Abarca H.^{1*}, Leonardo Solís O.^{1*}, Rodrigo Tapia F.^{1*}, Óscar Magna V.^{2*}

¹ Universidad Tecnológica Metropolitana (UTEM), Facultad de Ingeniería, Escuela de Informática, Ingeniería Civil en Computación mención Informática, Chile.

² Universidad Tecnológica Metropolitana (UTEM), Facultad de Ingeniería, Departamento de Informática y Computación, Chile.

* Autores (pabarc@utem.cl, l.soliso@utem.cl, rtapiaf@utem.cl)

* Coautor de correspondencia: Dr. Óscar Magna Veloso

Introducción

La agricultura global debe aumentar su producción en un 70% para 2050, alimentando a 9.000 millones de personas. India, segundo productor de arroz y con 50% de su población agrícola, enfrenta variabilidad climática (monzones) y pequeñas explotaciones, requiriendo soluciones IA accesibles y escalables.

Contexto Global: Agricultura inteligente para optimizar recursos y mitigar clima (datos históricos 1997-2020).

Foco en Arroz Indio: Variables climáticas (NASA POWER), edafológicas (WoSIS), agronómicas (fertilizantes, pesticidas, área), geográficas y temporales.

Rol de la IA: MLP comparado con 10 modelos ML para predecir yield, enfocado en pequeños productores.

Justificación: Hipótesis: Clima como predictor clave; dataset enriquecido (50 features) para robustez.

Proyecto promueve precisión agrícola, optimizando insumos para mayor productividad en recursos limitados.

Metodología

1. Adquisición y Enriquecimiento de Datos

- Dataset Base:** Se utilizaron datos históricos de producción de arroz en la India (1997-2020), filtrando el conjunto a 1,160 registros para un análisis enfocado.
- Enriquecimiento Externo:** Se integraron variables de fuentes especializadas para crear un dataset robusto con 50 características predictoras.
 - Datos Climáticos:** Temperatura y precipitación acumulada, obtenidos a través de la API de NASA POWER.
 - Datos Edafológicos:** Propiedades del suelo (pH, Nitrógeno, etc.) consultadas a la API WoSIS y complementadas mediante la generación de datos sintéticos basados en literatura científica.

2. Preprocesamiento de Datos

- Limpieza y Transformación:** Se realizó una limpieza de los datos, estandarizando las categorías temporales. Las variables categóricas como "Estado" y "Temporada" se transformaron mediante codificación *One-Hot Encoding*.
- Escalado de Características:** Todas las variables numéricas fueron normalizadas utilizando StandardScaler para evitar sesgos en los modelos debido a diferencias de escala.
- División del Dataset:** El conjunto de datos final se dividió en 80% para entrenamiento y 20% para prueba, asegurando una evaluación objetiva del rendimiento de los modelos.

3. Modelado y Comparación

Modelo Principal (MLP): Se diseñó y optimizó un Perceptrón Multicapa (red neuronal) con 3 capas ocultas, utilizando la función de activación ReLU y el optimizador Adam. Sus hiperparámetros clave fueron ajustados mediante una búsqueda en malla (*Grid Search*) para maximizar su rendimiento.

- Modelos de Comparación:** Se evaluó el MLP frente a otros 10 algoritmos de Machine Learning, incluyendo modelos de ensamble (*LightGBM*, *CatBoost*, *XGBoost*), modelos lineales (*Ridge*, *Lasso*) y otros enfoques clásicos (*Random Forest*, *SVR*, *KNN*).

4. Evaluación de Rendimiento

- Estrategia de Validación:** Se empleó una validación cruzada de 5 pliegues sobre el conjunto de entrenamiento para obtener una estimación robusta y fiable del rendimiento de cada modelo antes de la evaluación final.
- Métricas Finales:** El desempeño definitivo se midió sobre el conjunto de prueba utilizando métricas estándar para tareas de regresión: RMSE (Error Cuadrático Medio Raíz), MAE (Error Absoluto Medio) y R^2 (Coeficiente de Determinación).

Resultados




Figura 1: Comparación gráfica del rendimiento final de los modelos según RMSE, MAE y R^2 .




Figura 2: Grafico de dispersion: Predicciones vs Datos Reales MLP




Figura 3: Grafico de dispersion: Predicciones vs Datos Reales LightGBM

En este estudio, se evaluó el rendimiento de 11 modelos de aprendizaje automático para predecir el rendimiento del arroz en la India. El análisis se realizó en dos fases: una validación cruzada preliminar y una evaluación final sobre un conjunto de prueba no visto.

- Modelos de mejor rendimiento:** Los algoritmos de *Gradient Boosting* (LightGBM, CatBoost y XGBoost) demostraron una clara superioridad en todas las métricas. LightGBM se consolidó como el modelo ganador, alcanzando un R^2 de 0.552, lo que significa que puede explicar el 55.2% de la variabilidad en el rendimiento del cultivo.
- Rendimiento del MLP:** El Perceptrón Multicapa (MLP), el modelo central de este estudio, obtuvo un R^2 de 0.228 y un Error Absoluto Medio (MAE) de 0.044. Aunque cumplió la hipótesis de obtener un error inferior al 10% del rendimiento promedio, su capacidad predictiva fue significativamente menor que la de los modelos de ensamble basados en árboles.
- Factores de mayor impacto:** Contrario a la hipótesis inicial, el análisis del modelo LightGBM reveló que las variables de manejo agronómico (uso de fertilizantes y pesticidas) y el área cultivada fueron los predictores más influyentes, por sobre los factores climáticos y del suelo.
- Comparativa visual:** Los gráficos de dispersión (predicciones vs. valores reales) confirmaron visualmente el rendimiento superior de los modelos de *boosting*, mostrando una correlación lineal más definida en comparación con el MLP y otros modelos, cuyo rendimiento fue más disperso.

Conclusiones

Los modelos de gradient boosting superaron significativamente al MLP, destacando LightGBM ($R^2=0.552$) vs. MLP ($R^2=0.228$, MAE=0.044), con las variables de manejo (fertilizante, pesticida, área) como principales predictores, seguidas de factores climáticos y edáficos. Las limitaciones incluyen dependencia de imputaciones que introducen incertidumbre, sesgos geográficos y estacionales, y ausencia de series temporales largas e imágenes satelitales. Es posible obtener predicciones útiles con datos limitados, aunque la incorporación de NDVI y series de mayor resolución podría mejorar la precisión. Se recomienda optimizar LightGBM, incorporar datos espaciotemporales adicionales, mejorar la recolección de datos edáficos e implementar validación externa robusta. **Conclusión:** Los ensambles de árboles son la opción más efectiva; se debe priorizar la calidad de datos de manejo y suelo, e integrar fuentes temporales y espaciales para avanzar en agricultura de precisión.

Referencias

[1] Akshat Gupta et al. Agricultural crop yield in indian states dataset. <https://www.kaggle.com/datasets/akshatgupta7/crop-yield-in-indian-states-dataset>, 2023. Consultado: 29 de agosto de 2025.

[2] WoSIS - World Soil Information. Wosis (world soil information service) graphql api. <https://graphql.isric.org/wosis/graphql>, 2025. Consultado: 23 de septiembre de 2025.

[3] M Jayanthi, R Kalaiselvi, K Poongodi, and R Soumya. Critical analysis of soil for better rice and sugarcane

[4] Maps of India. Maps of india. <https://www.mapsofindia.com/>, 2025. Consultado: 03 de septiembre de 2025.

[5] NASA Langley Research Center (LaRC) POWER Project. Prediction of Worldwide Energy Resources (POWER)

[6] ISRIC - World Soil Information. Wosis (world soil information service) graphql api. <https://graphql.isric.org/wosis/graphql>, 2025. Consultado: 23 de septiembre de 2025.

[7] Maps of India. Maps of india. <https://www.mapsofindia.com/>, 2025. Consultado: 03 de septiembre de 2025.

[8] NASA Langley Research Center (LaRC) POWER Project. Prediction of Worldwide Energy Resources (POWER)

Agradecimientos

Queremos expresar nuestro sincero agradecimiento al Dr. Oscar Magna por su orientación y apoyo durante el desarrollo de este proyecto. Asimismo, agradecemos a todos aquellos que, de alguna forma, contribuyeron al éxito de este trabajo.